

大模型多模态期末试卷

满分 150 分 考试时间 150 分钟

注意事项：

- 本试卷共 三大题，包括选择题、填空题、解答题，共 **24** 小题。
- 请将答案写在答题区指定位置；解答题须写出必要的文字说明、推导过程或演算步骤。
- 涉及数学公式推导时，请清晰写出关键中间步骤；只写最终结果不得分。
- 本试卷中如无特殊说明，图像分辨率为 $H \times W$ ，patch 大小为 P ，视觉 token 数为 N_v ，文本序列长度为 L ，隐藏维度为 d ，对比学习温度系数为 τ ，扩散步数为 T ，批大小为 B 。

一、选择题（本大题共 12 小题，每小题 5 分，共 60 分。在每小题给出的四个选项中，只有一项是符合题目要求的。）

- 关于多模态大模型的三个核心问题——表示 (Representation)、对齐 (Alignment) 与融合 (Fusion)，下列说法正确的是
(A) 表示关注如何将不同模态映射到统一语义空间；对齐关注跨模态语义对应关系；融合关注多模态信息在下游任务中的联合利用
(B) 表示、对齐、融合三者完全等价，只是不同论文的命名差异
(C) 融合仅发生在预训练阶段，推理时不再需要跨模态交互
(D) 对齐问题仅存在于图文检索任务，在 VQA 等生成任务中不存在
- 关于 CLIP (Contrastive Language-Image Pre-training) 的核心训练机制，下列说法正确的是
(A) CLIP 采用单塔编码器，将图像与文本拼接后做自注意力融合
(B) CLIP 使用双塔结构分别编码图像与文本，通过批内对比学习 (InfoNCE) 拉近匹配图文对、推远不匹配对
(C) CLIP 的训练目标是最小化图像与文本在像素空间的均方误差 (MSE)
(D) CLIP 只能处理固定 224×224 图像，无法泛化到其他分辨率
- 设 Vision Transformer (ViT) 输入图像分辨率为 224×224 ，patch 大小为 16×16 ，并额外添加 1 个 CLS token。则送入 Transformer 编码器的序列长度为
(A) 14 (B) 196
(C) 197 (D) 225
- 下列多模态大模型架构与其核心连接器 (Connector) 的匹配，正确的是
(A) LLaVA —Q-Former; BLIP-2 —线性投影层; Flamingo —Perceiver Resampler
(B) LLaVA —线性/MLP 投影层; BLIP-2 —Q-Former; Flamingo —门控交叉注意力层 (Gated Cross-Attention)

(C) 三者均采用 Q-Former 作为唯一连接器

(D) LLaVA —扩散 U-Net; BLIP-2 —VAE 编码器; Flamingo —CLIP 文本塔

5. 关于 Early Fusion、Late Fusion 与 Intermediate Fusion (交叉注意力融合), 下列判断**错误**的是

(A) Early Fusion 在输入层即将多模态特征拼接或相加, 计算简单但模态异质性处理困难

(B) Late Fusion 各模态独立编码后在决策层融合, 模块化强但难以捕获细粒度跨模态交互

(C) Intermediate Fusion 通过 Cross-Attention 让一种模态的 Query 查询另一种模态的 Key/Value, 是 LLaVA、Flamingo 等的主流方案

(D) Late Fusion 一定优于 Intermediate Fusion, 因为避免了跨模态注意力带来的 $O(N_v^2)$ 计算开销

6. Stable Diffusion 属于 Latent Diffusion Model (LDM), 其核心设计是

(A) 直接在原始像素空间 $x \in \mathbb{R}^{H \times W \times 3}$ 上进行 T 步去噪

(B) 先用 VAE 将图像压缩到低维隐空间 z , 再在隐空间训练扩散去噪网络, 大幅降低计算量

(C) 完全放弃 VAE, 仅使用 GAN 判别器指导扩散过程

(D) 只在文本嵌入空间做扩散, 不生成任何图像

7. 关于 DDPM 前向加噪过程 $q(x_t|x_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}x_{t-1}, \beta_t I)$, 下列说法**正确**的是

(A) 前向过程是非马尔可夫的, 当前状态依赖全部历史步

(B) 当 $t \rightarrow T$ 且 $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s) \rightarrow 0$ 时, x_T 近似服从标准高斯分布

(C) 反向去噪过程 $q(x_{t-1}|x_t)$ 有解析闭式解, 可直接采样

(D) 方差调度 β_t 必须恒定为常数, 否则训练不稳定

8. 关于 VQ-VAE / VQ-GAN 中离散视觉 Token 化的机制, 下列说法**正确**的是

(A) Codebook 中每个向量通过 argmax 操作被选中, 梯度可通过 Straight-Through Estimator 近似回传

(B) 离散化后图像无法用 Transformer 建模, 必须退回 CNN

(C) VQ 损失仅包含重建损失, 不含 codebook 与 commitment 项

(D) Codebook 大小对生成质量无影响, 越大越好且无需担心码本利用率

9. CLIP 实现 Zero-shot 图像分类时, 对 C 个类别通常构造 C 个文本 prompt (如 “a photo of a {class}”), 预测类别为

(A) 与图像嵌入余弦相似度最大的文本嵌入所对应的类别

(B) 图像嵌入与各类别 one-hot 向量点积最大者

(C) 对 C 个 prompt 的文本嵌入取平均后, 与图像嵌入做 L2 距离最小者

(D) 随机从 C 个类别中采样, 与 CLIP 无关

10. Qwen-VL 等模型采用 M-RoPE (Multimodal Rotary Position Embedding) 处理图文混合序列, 其核心思想是

(A) 对文本 token 使用 1D 位置编码, 对视觉 token 使用 2D 空间位置编码 (行、列), 并在注意力中分别施加旋转

(B) 所有模态共享同一套绝对正弦位置编码, 不区分文本与图像

(C) 完全取消位置编码, 依赖 CLIP 预训练权重隐式编码位置

(D) 仅对 CLS token 施加 RoPE, patch token 不加位置信息

11. 关于视觉语言大模型中的对象幻觉 (Object Hallucination), 下列成因分析**最准确**的是

- (A) 幻觉完全由解码温度过高导致, Greedy Search 可彻底消除
- (B) 语言先验过强、视觉特征注入不足、训练数据中图文对齐噪声等因素, 使模型倾向于生成文本中常见但图像中不存在的对象
- (C) 幻觉仅发生在扩散模型中, 自回归 VLM 不会产生幻觉
- (D) 增大视觉 token 数量一定会加剧幻觉, 与语言模型容量无关

12. 在 CLIP 批内对比学习中, 设 batch 大小为 B , 图像嵌入为 $\{\mathbf{I}_i\}_{i=1}^B$, 文本嵌入为 $\{\mathbf{T}_i\}_{i=1}^B$ (均已 L2 归一化), 相似度 logits 为 $s_{ij} = \mathbf{I}_i^\top \mathbf{T}_j / \tau$ 。下列说法**正确**的是

- (A) 温度 τ 越小, softmax 分布越平滑, 负样本梯度越弱
- (B) 对角线元素 s_{ii} 为正样本对, 非对角线 $s_{ij} (i \neq j)$ 在图像到文本方向充当 in-batch 负样本; τ 越小分布越尖锐, 对困难负样本的区分力越强
- (C) 对比矩阵只需计算上三角, 因为 $s_{ij} = s_{ji}$ 恒成立
- (D) $B = 1$ 时 InfoNCE 仍能有效训练, 因为预训练数据足够大

二、填空题 (本大题共 6 小题, 每小题 5 分, 共 30 分。把答案填在题中横线上。)

13. 设 ViT 输入图像分辨率为 $H = W = 384$, patch 大小 $P = 16$, 使用 1 个 CLS token。则 patch 数量为 $N_v =$ _____, 送入 Transformer 的总序列长度为 _____。

14. CLIP 对称 InfoNCE 损失 (图像到文本方向) 可写为

$$\mathcal{L}_{I \rightarrow T} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(\mathbf{I}_i^\top \mathbf{T}_i / \tau)}{\sum_{j=1}^B \exp(\mathbf{I}_i^\top \mathbf{T}_j / \tau)}.$$

完整对称损失为 $\mathcal{L}_{\text{CLIP}} =$ _____。

15. 在 CLIP 批内对比学习中, batch 大小为 B 时, 对于样本 i , 图像到文本方向的 in-batch 负样本数量为 _____; 图像—文本相似度矩阵规模为 _____。

16. 设视觉 token 数 $N_v = 576$, 隐藏维度 $d = 1024$, 注意力头数 $h = 16$ 。单层视觉自注意力中, $QK^\top$ 矩阵的显存占用 (fp16, 每元素 2 字节) 约为 _____ MB (保留整数)。

17. DDPM 前向过程定义 $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 。则 $q(x_t|x_0)$ 的闭式分布为

$$q(x_t|x_0) = \mathcal{N}(\text{_____}, \text{_____}).$$

18. BLIP-2 中 Q-Former 使用 N_q 个可学习 query token 通过交叉注意力从冻结的视觉编码器输出中抽取特征。若 $N_q = 32$, 视觉编码器输出序列长度为 $N_v = 257$ (含 CLS), 则 Q-Former 输出的视觉 token 数为 _____; 相比直接将 N_v 个 token 送入 LLM, LLM 侧序列长度减少比例为 _____ (保留两位小数)。

三、解答题 (本大题共 6 小题, 共 60 分。解答应写出文字说明、证明过程或演算步骤。)

19. (本小题满分 10 分)

CLIP 通过批内对比学习实现图文对齐。设 batch 大小为 B ，L2 归一化后的图像嵌入为 $\mathbf{I}_i$ ，文本嵌入为 $\mathbf{T}_i$ ，温度系数为 τ ，相似度 $s_{ij} = \mathbf{I}_i^\top \mathbf{T}_j / \tau$ 。

- (1) 写出 CLIP 对称 InfoNCE 损失的完整表达式（图像 $\rightarrow$ 文本与文本 $\rightarrow$ 图像两个方向）；（3 分）
- (2) 分析温度系数 τ 对 softmax 分布与梯度的影响： τ 增大和减小时分别有何效果？（3 分）
- (3) 对图像到文本方向，求 $\mathcal{L}_{I \rightarrow T}$ 关于正样本 logit s_{ii} 的梯度 $\partial \mathcal{L}_{I \rightarrow T} / \partial s_{ii}$ ，并解释其直觉含义。（4 分）

20. (本小题满分 10 分)

设 ViT 输入图像 $H \times W$, patch 大小 $P \times P$, 隐藏维度 d , 注意力头数 h , 每头维度 $d_h = d/h$, 编码器层数 L_{enc} 。

- (1) 推导 patch 数量 N_v 与总序列长度 N (含 CLS token) 的表达式; (2 分)
- (2) 推导单层 ViT 编码器中 Self-Attention 前向传播的 FLOPs (含 Q, K, V 投影、 $QK^\top$ 、 $\text{softmax}(QK^\top)V$ 、输出投影), 用 N, d, h 表示; (4 分)
- (3) 若图像分辨率从 224×224 提升至 448×448 (P 不变), 分析 N 、单层注意力 FLOPs 及注意力矩阵显存的变化倍数。(4 分)

21. (本小题满分 10 分)

设 DDPM 前向过程为 $q(x_t|x_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}x_{t-1}, \beta_t I)$, $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 。

- (1) 利用马尔可夫性质与重参数化技巧, 推导 $q(x_t|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)I)$ 的完整过程; (5 分)
- (2) 说明为何训练目标可简化为 $\mathcal{L}_{\text{simple}} = \mathbb{E}_{t,x_0,\epsilon} [\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$, 其中 $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$, $\epsilon \sim \mathcal{N}(0, I)$ 。(5 分)

22. (本小题满分 10 分)

LLaVA 将预训练视觉编码器 (如 CLIP ViT) 与 LLM 通过轻量投影器连接, 采用两阶段训练策略。

- (1) 画出 LLaVA 前向数据流: 从原始图像到 LLM 输出的完整路径, 标注视觉编码器、投影器、LLM 各阶段的输入输出维度变化; (4 分)
- (2) 对比阶段一 (特征对齐预训练) 与阶段二 (端到端指令微调) 的训练目标、冻结策略与数据形式; (3 分)
- (3) 若视觉编码器输出 $N_v = 576$ 个 token, LLM 最大上下文 4096 token, 用户文本平均 200 token。估算视觉 token 占上下文的比例, 并说明为何高分辨率场景下需要 AnyRes 或 token 压缩。(3 分)

23. (本小题满分 10 分)

BLIP-2 的 Q-Former 与 Flamingo 的 Perceiver Resampler 均通过可学习 query 压缩视觉特征。

- (1) 描述 Q-Former 的结构: 可学习 query 如何通过 Cross-Attention 从冻结 ViT 输出 $H_v \in \mathbb{R}^{N_v \times d_v}$ 中提取 N_q 个视觉 token; (4 分)
- (2) 对比 Q-Former 与 Flamingo Perceiver Resampler 的异同 (输入、注意力类型、输出用途); (3 分)
- (3) 设 $N_v = 1024$, $N_q = 64$, $d = 4096$, LLM 层数 $L = 32$ 。估算将 N_v 个 token 直接送入 LLM 与经 Q-Former 压缩后, LLM 侧 KV Cache 显存 (fp16) 的节省倍数。(3 分)

24. (本小题满分 10 分, 压轴)

某多模态推理服务部署单卡 A100-80GB, 模型为 7B VLM (fp16), 视觉编码器 ViT-L ($N_v^{\max} = 576$), LLM 最大上下文 32k token。负载包括: (a) 高分辨率文档 OCR (单图 2048×2048 , AnyRes 切为 4 子图); (b) 长视频理解 (30 fps, 10 秒片段, 每帧采样 1 次); (c) 在线图文对话 (平均 2k 文本 token)。系统观察到: 高分辨率请求导致 P99 延迟毛刺; 视频任务频繁 OOM; 并发提升后 GPU 利用率仅 40%。

- (1) 分析现象 (a) 的根因, 说明 AnyRes 切图后视觉 token 数量的计算方式, 以及 token 合并 (如 2×2 pooling) 如何缓解; (3 分)
- (2) 针对现象 (b), 设计包含帧采样、视觉 token 压缩、跨帧 KV Cache 复用的方案, 并量化 10 秒视频的视觉 token 总数 (设每帧 $N_v = 576$, 压缩比 4:1); (4 分)
- (3) 针对现象 (c), 结合 Continuous Batching、视觉编码器批处理、Prefix Caching (复用 System Prompt 与共享图像 KV), 给出至少 3 项优化方向及预期收益。(3 分)

参考答案与解析

命题：大模型多模态课程组 校对：教研组

一、选择题答案

1. A	4. B	7. B	10. A
2. B	5. D	8. A	11. B
3. C	6. B	9. A	12. B

- A** 多模态三要素：表示解决”如何编码各模态”；对齐解决”不同模态语义如何对应”；融合解决”多模态信息如何联合用于下游任务”。三者递进且相互关联。B 错误：三者含义不同；C 错误：推理时仍需 cross-attention 等融合；D 错误：VQA 等生成任务同样需要对齐。
- B** CLIP 采用图像编码器与文本编码器双塔结构，批内 B 个图文对构成 $B \times B$ 相似度矩阵，对角线为正样本、非对角线为负样本，用 InfoNCE 对比损失训练。A 描述的是单塔融合架构；C 是像素级重建而非语义对齐；D 错误：ViT 可通过插值泛化到其他分辨率。
- C** Patch 数量 $N_v = (224/16)^2 = 14^2 = 196$ ，加 1 个 CLS token 后总序列长度 $N = 196 + 1 = 197$ 。
- B** LLaVA 用线性或 MLP 将 ViT 输出投影到 LLM 词嵌入空间；BLIP-2 用 Q-Former（可学习 query + 交叉注意力）桥接冻结 ViT 与 LLM；Flamingo 在 LLM 层间插入门控交叉注意力，使文本 token 查询视觉特征。
- D** Late Fusion 虽简单，但无法在中间层捕获细粒度跨模态交互（如”图中红色物体”与”the red object”的 token 级对齐），Intermediate Fusion 在 VQA、Caption 等任务上通常更优。A、B、C 均为正确描述。
- B** LDM 先用 VAE 编码器将图像压缩为低维 z （如 $64 \times 64 \times 4$ ），在 z 空间训练 U-Net 去噪，解码时用 VAE 解码器还原图像，计算量远低于像素空间扩散。
- B** 前向过程是马尔可夫链；当 $t \rightarrow T$ ， $\bar{\alpha}_t \rightarrow 0$ ， x_t 近似 $\mathcal{N}(0, I)$ 。反向 $q(x_{t-1}|x_t)$ 未知，需学习 $p_\theta(x_{t-1}|x_t)$ ； β_t 通常采用线性或 cosine 调度，非常数。
- A** VQ 将连续特征量化为 codebook 索引，argmax 不可微，常用 Straight-Through：前向用离散索引，反向梯度直通编码器输出。B 错误：DALL-E、Parti 等用离散 token + Transformer；C 错误：VQ 损失含 codebook、commitment、重建项；D 错误：码本过大易导致利用率低。
- A** Zero-shot 分类：构造 C 个 prompt，编码后与图像嵌入算余弦相似度，取最大者对应类别。无需训练分类头，体现 CLIP 的开放词汇能力。
- A** M-RoPE 对文本用 1D 位置，对视觉 token 用 2D (h, w) 位置，在 RoPE 旋转中分别处理，使模型感知空间结构。B、C、D 均不符合 Qwen-VL 等设计。
- B** 对象幻觉成因：语言先验（”狗”常伴”草地”）过强、视觉注入不足、训练噪声、解码随机性等。A 错误：Greedy 仍可能幻觉；C 错误：VLM 普遍存在；D 错误：适量视觉 token 有助于 grounding，幻觉是多方因素。
- B** 对角线 s_{ii} 为正样本； τ 越小 softmax 越尖锐，对困难负样本梯度越大。A 错误： τ 小则分

布更尖锐；C 错误：图像—文本矩阵一般不对称（ $s_{ij} \neq s_{ji}$ 当使用不同编码器时）；D 错误： $B = 1$ 无负样本，对比学习失效。

二、填空题答案

13. $N_v = (384/16)^2 = 24^2 = 576$ ； 总序列长度 $N = 576 + 1 = 577$ 。
 14. $\mathcal{L}_{\text{CLIP}} = \frac{1}{2}(\mathcal{L}_{I \rightarrow T} + \mathcal{L}_{T \rightarrow I})$ ，其中 $\mathcal{L}_{T \rightarrow I}$ 为文本到图像方向的 InfoNCE，形式与 $\mathcal{L}_{I \rightarrow T}$ 对称。
 15. 负样本数 $= B - 1$ ； 相似度矩阵规模 $= B \times B$ 。
 16. $QK^\top$ 规模为 576×576 ，fp16 显存 $= 576^2 \times 2 = 663552$ 字节 ≈ 0.66 MB，保留整数为 1 MB。
 17. 均值 $\sqrt{\bar{\alpha}_t} x_0$ ； 方差 $(1 - \bar{\alpha}_t)I$ （或协方差矩阵 $(1 - \bar{\alpha}_t)I$ ）。
 18. 输出视觉 token 数 $= 32$ ； 减少比例 $= 1 - 32/257 \approx 0.88$ （或 $(257 - 32)/257 \approx 0.88$ ）。

三、解答题答案

19. CLIP 对比学习 (10 分)

(1) 对称 InfoNCE (3 分)

$$\mathcal{L}_{I \rightarrow T} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(s_{ii})}{\sum_{j=1}^B \exp(s_{ij})}, \quad \mathcal{L}_{T \rightarrow I} = -\frac{1}{B} \sum_{j=1}^B \log \frac{\exp(s_{jj})}{\sum_{i=1}^B \exp(s_{ij})},$$

$$\mathcal{L}_{\text{CLIP}} = \frac{1}{2}(\mathcal{L}_{I \rightarrow T} + \mathcal{L}_{T \rightarrow I}).$$

(2) 温度 τ 的影响 (3 分)

τ 增大：logits s_{ij}/τ 变小，softmax 分布更平滑，所有样本（含负样本）获得更均匀的梯度，学习更稳定但区分力下降。 τ 减小：分布更尖锐，模型更关注困难负样本（高相似度但不匹配的对），梯度集中在少数样本，有利于细粒度对齐但可能训练不稳定。CLIP 典型 $\tau \approx 0.07$ 。

(3) 正样本 logit 梯度 (4 分)

记 $p_{ij} = \exp(s_{ij}) / \sum_k \exp(s_{ik})$ ，则 $\mathcal{L}_{I \rightarrow T} = -\frac{1}{B} \sum_i \log p_{ii}$ ，故

$$\frac{\partial \mathcal{L}_{I \rightarrow T}}{\partial s_{ii}} = -\frac{1}{B}(1 - p_{ii}).$$

直觉： p_{ii} 越接近 1（正样本已很好区分），梯度越接近 0； p_{ii} 小时梯度为负且绝对值大，推动 s_{ii} 增大，拉近正样本对。

20. ViT 计算量推导 (10 分)

(1) 序列长度 (2 分)

$N_v = \frac{H}{P} \cdot \frac{W}{P}$ ，总序列长度 $N = N_v + 1$ （含 CLS）。

(2) 单层 Self-Attention FLOPs (4 分)

Q, K, V 投影：各 $2Nd^2$ ，共 $6Nd^2$ 。 $S = QK^\top$ ： $2N^2d$ 。 $O = \text{softmax}(S)V$ ： $2N^2d$ 。输出投影： $2Nd^2$ 。
 单层注意力合计 $\approx 8Nd^2 + 4N^2d$ FLOPs。

(3) 分辨率翻倍的影响 (4 分)

224 → 448: N_v 从 $14^2 = 196$ 增至 $28^2 = 784$, 约 4 倍。 N 从 197 增至 785。注意力 FLOPs 中 N^2d 项增约 $4^2 = 16$ 倍, Nd^2 项增 4 倍; 显存 $N \times N$ 注意力矩阵增 16 倍。故高分辨率是视觉 token 爆炸的主要来源。

21. 扩散模型推导 (10 分)

(1) $q(x_t|x_0)$ 闭式解 (5 分)

由 $x_t = \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\epsilon_{t-1}$ 递推, 归纳得

$$x_t = \sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\bar{\epsilon}, \quad \bar{\epsilon} \sim \mathcal{N}(0, I),$$

即 $q(x_t|x_0) = \mathcal{N}(\sqrt{\alpha_t}x_0, (1 - \alpha_t)I)$ 。

(2) 简化为噪声预测 (5 分)

原始 ELBO 含多步 KL 项。在 $x_t = \sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\epsilon$ 下, x_0 与 ϵ 一一对应。预测 x_0 等价于预测 ϵ , Ho 等证明加权变分下界可简化为 $\mathbb{E}[\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$, 即直接学习噪声, 训练更稳定且效果相当。

22. LLaVA 架构与训练 (10 分)

(1) 数据流 (4 分)

图像 → ViT → $[N_v \times d_v]$ → 投影器 (Linear/MLP) → $[N_v \times d_{\text{LLM}}]$ → 与文本 token 嵌入拼接 → LLM 自回归生成。投影器将视觉特征映射到 LLM 词嵌入空间。

(2) 两阶段对比 (3 分)

阶段一: 冻结 ViT 与 LLM, 只训练投影器, 用图文对 (如 CC3M) 做 next-token 预测, 学习视觉—语言对齐。阶段二: 解冻 LLM (或 LoRA), 用指令数据 (VQA、对话) 端到端微调, 学习遵循指令与推理。

(3) Token 预算 (3 分)

视觉占比 = $576/(576 + 200) \approx 74\%$ 。高分辨率时 N_v 可超 2k, 易占满 4k 上下文, 需 AnyRes 切图后选择性编码, 或 2×2 pooling 合并 token, 或 Q-Former 压缩。

23. Q-Former 与 Perceiver Resampler (10 分)

(1) Q-Former 结构 (4 分)

N_q 个可学习 query $\mathbf{Q} \in \mathbb{R}^{N_q \times d}$ 作为 Query, ViT 输出 H_v 作为 Key/Value, 经 Cross-Attention: $\text{Attn}(\mathbf{Q}, H_v, H_v)$, 输出 N_q 个视觉 token。ViT 冻结, 只训练 Q-Former 与后续 LLM 接口。

(2) 异同 (3 分)

Q-Former: 独立 BERT 式模块, 输出接 LLM 投影; Flamingo Perceiver Resampler: 在 Flamingo 框架内, 用固定数量 latent 查询视觉特征, 输出注入 LLM 交叉注意力层。二者均为“少量 query + Cross-Attn”压缩, 但集成方式不同。

(3) KV Cache 节省 (3 分)

LLM KV Cache 与序列长度成正比。直接输入: $N_v = 1024$; 压缩后: $N_q = 64$ 。节省倍数 = $1024/64 = 16$ 。32 层 fp16: 约 $2 \times L \times N \times d \times 2$ 字节, 序列减 16 倍则 KV Cache 减 16 倍。

24. 压轴题: 多模态推理系统优化 (10 分)

(1) 高分辨率延迟毛刺 (3 分)

根因：2048 × 2048 单图 AnyRes 切 4 子图，每子图 $N_v \approx 576$ ，总视觉 token $\approx 4 \times 576 = 2304$ ，Prefill 计算量 $\propto N^2$ ，阻塞 Decode。Token 合并：2×2 pooling 将每子图 576 压至 144，总 token $4 \times 144 = 576$ ，减 75%。

(2) 长视频 OOM 方案 (4 分)

10 秒 30 fps 采样 300 帧。每帧 576 token，压缩比 4:1 后每帧 144 token，总视觉 token = $300 \times 144 = 43200$ 。方案：帧采样（如 1 fps 得 10 帧）、Perceiver 压缩、跨帧 KV 复用（相邻帧共享前缀）。优化后 10 帧 × 144 = 1440 token，可纳入 32k 上下文。

(3) 并发与利用率 (3 分)

(1) Continuous Batching：请求级调度，完成即释放，提高并发；(2) 视觉编码器批处理：多图拼 batch 提升 ViT 利用率；(3) Prefix Caching：复用 System Prompt 与共享图像 KV，减少重复 Prefill。预期：SM 利用率从 40% 提升至 60%+，P99 延迟降低 30%+。