

大模型多模态期末试卷

满分 150 分 考试时间 150 分钟

命题范围：视觉编码与 ViT / 对比学习与 CLIP / 模态融合与连接器 / 扩散生成 / 离散视觉 Token / 多模态位置编码 / 对齐与指令微调 / 系统效率与幻觉

注意事项：

- 本试卷共 三大题，包括选择题、填空题、解答题，共 **24** 小题。
- 请将答案写在答题区指定位置；解答题须写出必要的文字说明、推导过程或演算步骤。
- 涉及数学公式推导时，请清晰写出关键中间步骤；只写最终结果不得分。
- 本试卷中如无特殊说明，图像分辨率为 $H \times W$ ，patch 大小为 P ，视觉 token 数为 N_v ，文本序列长度为 L ，隐藏维度为 d ，对比学习温度系数为 τ ，扩散步数为 T ，批大小为 B 。

一、选择题（本大题共 12 小题，每小题 5 分，共 60 分。在每小题给出的四个选项中，只有一项是符合题目要求的。）

1. 关于多模态大模型的三个核心问题——表示 (Representation)、对齐 (Alignment) 与融合 (Fusion)，下列说法**正确**的是

- (A) 表示关注如何将不同模态映射到统一语义空间；对齐关注跨模态语义对应关系；融合关注多模态信息在下游任务中的联合利用
- (B) 表示、对齐、融合三者完全等价，只是不同论文的命名差异
- (C) 融合仅发生在预训练阶段，推理时不再需要跨模态交互
- (D) 对齐问题仅存在于图文检索任务，在 VQA 等生成任务中不存在

2. 关于 CLIP (Contrastive Language-Image Pre-training) 的核心训练机制，下列说法**正确**的是

- (A) CLIP 采用单塔编码器，将图像与文本拼接后做自注意力融合
- (B) CLIP 使用双塔结构分别编码图像与文本，通过批内对比学习 (InfoNCE) 拉近匹配图文对、推远不匹配对
- (C) CLIP 的训练目标是最小化图像与文本在像素空间的均方误差 (MSE)
- (D) CLIP 只能处理固定 224×224 图像，无法泛化到其他分辨率

3. 设 Vision Transformer (ViT) 输入图像分辨率为 224×224 ，patch 大小为 16×16 ，并额外添加 1 个 CLS token。则送入 Transformer 编码器的序列长度为

- (A) 14
- (B) 196
- (C) 197
- (D) 225

4. 下列多模态大模型架构与其核心连接器 (Connector) 的匹配，**正确**的是

- (A) LLaVA —Q-Former; BLIP-2 —线性投影层; Flamingo —Perceiver Resampler
- (B) LLaVA —线性/MLP 投影层; BLIP-2 —Q-Former; Flamingo —门控交叉注意力层 (Gated Cross-Attention)
- (C) 三者均采用 Q-Former 作为唯一连接器
- (D) LLaVA —扩散 U-Net; BLIP-2 —VAE 编码器; Flamingo —CLIP 文本塔

5. 关于 Early Fusion、Late Fusion 与 Intermediate Fusion (交叉注意力融合), 下列判断**错误**的是

- (A) Early Fusion 在输入层即将多模态特征拼接或相加, 计算简单但模态异质性处理困难
- (B) Late Fusion 各模态独立编码后在决策层融合, 模块化强但难以捕获细粒度跨模态交互
- (C) Intermediate Fusion 通过 Cross-Attention 让一种模态的 Query 查询另一种模态的 Key/Value, 是 LLaVA、Flamingo 等的主流方案
- (D) Late Fusion 一定优于 Intermediate Fusion, 因为避免了跨模态注意力带来的 $O(N_v^2)$ 计算开销

6. Stable Diffusion 属于 Latent Diffusion Model (LDM), 其核心设计是

- (A) 直接在原始像素空间 $x \in \mathbb{R}^{H \times W \times 3}$ 上进行 T 步去噪
- (B) 先用 VAE 将图像压缩到低维隐空间 z , 再在隐空间训练扩散去噪网络, 大幅降低计算量
- (C) 完全放弃 VAE, 仅使用 GAN 判别器指导扩散过程
- (D) 只在文本嵌入空间做扩散, 不生成任何图像

7. 关于 DDPM 前向加噪过程 $q(x_t|x_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}x_{t-1}, \beta_t I)$, 下列说法**正确**的是

- (A) 前向过程是非马尔可夫的, 当前状态依赖全部历史步
- (B) 当 $t \rightarrow T$ 且 $\bar{\alpha}_t = \prod_{s=1}^t (1-\beta_s) \rightarrow 0$ 时, x_T 近似服从标准高斯分布
- (C) 反向去噪过程 $q(x_{t-1}|x_t)$ 有解析闭式解, 可直接采样
- (D) 方差调度 β_t 必须恒定为常数, 否则训练不稳定

8. 关于 VQ-VAE / VQ-GAN 中离散视觉 Token 化的机制, 下列说法**正确**的是

- (A) Codebook 中每个向量通过 argmax 操作被选中, 梯度可通过 Straight-Through Estimator 近似回传
- (B) 离散化后图像无法用 Transformer 建模, 必须退回 CNN
- (C) VQ 损失仅包含重建损失, 不含 codebook 与 commitment 项
- (D) Codebook 大小对生成质量无影响, 越大越好且无需担心码本利用率

9. CLIP 实现 Zero-shot 图像分类时, 对 C 个类别通常构造 C 个文本 prompt (如 “a photo of a {class}”), 预测类别为

- (A) 与图像嵌入余弦相似度最大的文本嵌入所对应的类别
- (B) 图像嵌入与各类别 one-hot 向量点积最大者
- (C) 对 C 个 prompt 的文本嵌入取平均后, 与图像嵌入做 L2 距离最小者
- (D) 随机从 C 个类别中采样, 与 CLIP 无关

10. Qwen-VL 等模型采用 M-RoPE (Multimodal Rotary Position Embedding) 处理图文混合序列, 其核心思想是

- (A) 对文本 token 使用 1D 位置编码, 对视觉 token 使用 2D 空间位置编码 (行、列), 并在注意力中分别施加旋转

- (B) 所有模态共享同一套绝对正弦位置编码，不区分文本与图像
- (C) 完全取消位置编码，依赖 CLIP 预训练权重隐式编码位置
- (D) 仅对 CLS token 施加 RoPE，patch token 不加位置信息

11. 关于视觉语言大模型中的对象幻觉 (Object Hallucination)，下列成因分析**最准确**的是

- (A) 幻觉完全由解码温度过高导致，Greedy Search 可彻底消除
- (B) 语言先验过强、视觉特征注入不足、训练数据中图文对齐噪声等因素，使模型倾向于生成文本中常见但图像中不存在的对象
- (C) 幻觉仅发生在扩散模型中，自回归 VLM 不会产生幻觉
- (D) 增大视觉 token 数量一定会加剧幻觉，与语言模型容量无关

12. 在 CLIP 批内对比学习中，设 batch 大小为 B ，图像嵌入为 $\{\mathbf{I}_i\}_{i=1}^B$ ，文本嵌入为 $\{\mathbf{T}_i\}_{i=1}^B$ (均已 L2 归一化)，相似度 logits 为 $s_{ij} = \mathbf{I}_i^\top \mathbf{T}_j / \tau$ 。下列说法**正确**的是

- (A) 温度 τ 越小，softmax 分布越平滑，负样本梯度越弱
- (B) 对角线元素 s_{ii} 为正样本对，非对角线 $s_{ij} (i \neq j)$ 在图像到文本方向充当 in-batch 负样本； τ 越小分布越尖锐，对困难负样本的区分力越强
- (C) 对比矩阵只需计算上三角，因为 $s_{ij} = s_{ji}$ 恒成立
- (D) $B = 1$ 时 InfoNCE 仍能有效训练，因为预训练数据足够大

二、填空题 (本大题共 6 小题，每小题 5 分，共 30 分。把答案填在题中横线上。)

13. 设 ViT 输入图像分辨率为 $H = W = 384$ ，patch 大小 $P = 16$ ，使用 1 个 CLS token。则 patch 数量为 $N_v =$ _____，送入 Transformer 的总序列长度为 _____。

14. CLIP 对称 InfoNCE 损失 (图像到文本方向) 可写为

$$\mathcal{L}_{I \rightarrow T} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(\mathbf{I}_i^\top \mathbf{T}_i / \tau)}{\sum_{j=1}^B \exp(\mathbf{I}_i^\top \mathbf{T}_j / \tau)}.$$

完整对称损失为 $\mathcal{L}_{\text{CLIP}} =$ _____。

15. 在 CLIP 批内对比学习中，batch 大小为 B 时，对于样本 i ，图像到文本方向的 in-batch 负样本数量为 _____；图像—文本相似度矩阵规模为 _____。

16. 设视觉 token 数 $N_v = 576$ ，隐藏维度 $d = 1024$ ，注意力头数 $h = 16$ 。单层视觉自注意力中， $QK^\top$ 矩阵的显存占用 (fp16，每元素 2 字节) 约为 _____ MB (保留整数)。

17. DDPM 前向过程定义 $\alpha_t = 1 - \beta_t$ ， $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 。则 $q(x_t|x_0)$ 的闭式分布为

$$q(x_t|x_0) = \mathcal{N}(\text{_____}, \text{_____}).$$

18. BLIP-2 中 Q-Former 使用 N_q 个可学习 query token 通过交叉注意力从冻结的视觉编码器输出中抽取特征。若 $N_q = 32$ ，视觉编码器输出序列长度为 $N_v = 257$ (含 CLS)，则 Q-Former 输出的视觉 token 数为 _____；相比直接将 N_v 个 token 送入 LLM，LLM 侧序列长度减少比例为 _____ (保留两位小数)。

三、解答题 (本大题共 6 小题，共 60 分。解答应写出文字说明、证明过程或演算步骤。)

20. (本小题满分 10 分)

设 ViT 输入图像 $H \times W$, patch 大小 $P \times P$, 隐藏维度 d , 注意力头数 h , 每头维度 $d_h = d/h$, 编码器层数 L_{enc} 。

- (1) 推导 patch 数量 N_v 与总序列长度 N (含 CLS token) 的表达式; (2 分)
- (2) 推导单层 ViT 编码器中 Self-Attention 前向传播的 FLOPs (含 Q, K, V 投影、 $QK^\top$ 、 $\text{softmax}(QK^\top)V$ 、输出投影), 用 N, d, h 表示; (4 分)
- (3) 若图像分辨率从 224×224 提升至 448×448 (P 不变), 分析 N 、单层注意力 FLOPs 及注意力矩阵显存的变化倍数。(4 分)

解：

[illegible]

[illegible]

参考答案与解析

命题：大模型多模态课程组 校对：教研组

一、选择题答案

1. A	4. B	7. B	10. A
2. B	5. D	8. A	11. B
3. C	6. B	9. A	12. B

1. **A** 多模态三要素：表示解决”如何编码各模态”；对齐解决”不同模态语义如何对应”；融合解决”多模态信息如何联合用于下游任务”。三者递进且相互关联。B 错误：三者含义不同；C 错误：推理时仍需 cross-attention 等融合；D 错误：VQA 等生成任务同样需要对齐。
2. **B** CLIP 采用图像编码器与文本编码器双塔结构，批内 B 个图文对构成 $B \times B$ 相似度矩阵，对角线为正样本、非对角线为负样本，用 InfoNCE 对比损失训练。A 描述的是单塔融合架构；C 是像素级重建而非语义对齐；D 错误：ViT 可通过插值泛化到其他分辨率。
3. **C** Patch 数量 $N_v = (224/16)^2 = 14^2 = 196$ ，加 1 个 CLS token 后总序列长度 $N = 196 + 1 = 197$ 。
4. **B** LLaVA 用线性或 MLP 将 ViT 输出投影到 LLM 词嵌入空间；BLIP-2 用 Q-Former（可学习 query + 交叉注意力）桥接冻结 ViT 与 LLM；Flamingo 在 LLM 层间插入门控交叉注意力，使文本 token 查询视觉特征。
5. **D** Late Fusion 虽简单，但无法在中间层捕获细粒度跨模态交互（如”图中红色物体”与”the red object”的 token 级对齐），Intermediate Fusion 在 VQA、Caption 等任务上通常更优。A、B、C 均为正确描述。
6. **B** LDM 先用 VAE 编码器将图像压缩为低维 z （如 $64 \times 64 \times 4$ ），在 z 空间训练 U-Net 去噪，解码时用 VAE 解码器还原图像，计算量远低于像素空间扩散。
7. **B** 前向过程是马尔可夫链；当 $t \rightarrow T$ ， $\bar{\alpha}_t \rightarrow 0$ ， x_t 近似 $\mathcal{N}(0, I)$ 。反向 $q(x_{t-1}|x_t)$ 未知，需学习 $p_\theta(x_{t-1}|x_t)$ ； β_t 通常采用线性或 cosine 调度，非常数。
8. **A** VQ 将连续特征量化为 codebook 索引，argmax 不可微，常用 Straight-Through：前向用离散索引，反向梯度直通编码器输出。B 错误：DALL-E、Parti 等用离散 token + Transformer；C 错误：VQ 损失含 codebook、commitment、重建项；D 错误：码本过大易导致利用率低。
9. **A** Zero-shot 分类：构造 C 个 prompt，编码后与图像嵌入算余弦相似度，取最大者对应类别。无需训练分类头，体现 CLIP 的开放词汇能力。
10. **A** M-RoPE 对文本用 1D 位置，对视觉 token 用 2D (h, w) 位置，在 RoPE 旋转中分别处理，使模型感知空间结构。B、C、D 均不符合 Qwen-VL 等设计。
11. **B** 对象幻觉成因：语言先验（”狗”常伴”草地”）过强、视觉注入不足、训练噪声、解码随机性等。A 错误：Greedy 仍可能幻觉；C 错误：VLM 普遍存在；D 错误：适量视觉 token 有助于 grounding，幻觉是多方因素。
12. **B** 对角线 s_{ii} 为正样本； τ 越小 softmax 越尖锐，对困难负样本梯度越大。A 错误： τ 小则分

布更尖锐；C 错误：图像—文本矩阵一般不对称（ $s_{ij} \neq s_{ji}$ 当使用不同编码器时）；D 错误： $B = 1$ 无负样本，对比学习失效。

二、填空题答案

13. $N_v = (384/16)^2 = 24^2 = 576$ ； 总序列长度 $N = 576 + 1 = 577$ 。
 14. $\mathcal{L}_{\text{CLIP}} = \frac{1}{2}(\mathcal{L}_{I \rightarrow T} + \mathcal{L}_{T \rightarrow I})$ ，其中 $\mathcal{L}_{T \rightarrow I}$ 为文本到图像方向的 InfoNCE，形式与 $\mathcal{L}_{I \rightarrow T}$ 对称。
 15. 负样本数 = $B - 1$ ； 相似度矩阵规模 = $B \times B$ 。
 16. $QK^\top$ 规模为 $N_v \times N_v = 576 \times 576$ ，fp16 显存 = $576^2 \times 2 = 663\,552$ 字节 ≈ 0.63 MB，取整 1 MB（若按 $331\,776 \times 2$ 精确值 $663\,552$ B ≈ 0.65 MB，保留整数为 1）。更精确： $576^2 \times 2/10^6 \approx 0.66$ ，题目保留整数填 1 或 0.66 视单位约定；标准答案取 1 MB（约 0.66 MB 四舍五入）。
 17. 均值 $\sqrt{\bar{\alpha}_t} x_0$ ； 方差 $(1 - \bar{\alpha}_t)I$ （或协方差矩阵 $(1 - \bar{\alpha}_t)I$ ）。
 18. 输出视觉 token 数 = 32 ； 减少比例 = $1 - 32/257 \approx 0.88$ （或 $(257 - 32)/257 \approx 0.88$ ）。

三、解答题答案

19. CLIP 对比学习 (10 分)

(1) 对称 InfoNCE (3 分)

$$\mathcal{L}_{I \rightarrow T} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(s_{ii})}{\sum_{j=1}^B \exp(s_{ij})}, \quad \mathcal{L}_{T \rightarrow I} = -\frac{1}{B} \sum_{j=1}^B \log \frac{\exp(s_{jj})}{\sum_{i=1}^B \exp(s_{ij})},$$

$$\mathcal{L}_{\text{CLIP}} = \frac{1}{2}(\mathcal{L}_{I \rightarrow T} + \mathcal{L}_{T \rightarrow I}).$$

(2) 温度 τ 的影响 (3 分)

τ 增大：logits s_{ij}/τ 变小，softmax 分布更平滑，所有样本（含负样本）获得更均匀的梯度，学习更稳定但区分力下降。 τ 减小：分布更尖锐，模型更关注困难负样本（高相似度但不匹配的对），梯度集中在少数样本，有利于细粒度对齐但可能训练不稳定。CLIP 典型 $\tau \approx 0.07$ 。

(3) 正样本 logit 梯度 (4 分)

记 $p_{ij} = \exp(s_{ij}) / \sum_k \exp(s_{ik})$ ，则 $\mathcal{L}_{I \rightarrow T} = -\frac{1}{B} \sum_i \log p_{ii}$ ，故

$$\frac{\partial \mathcal{L}_{I \rightarrow T}}{\partial s_{ii}} = -\frac{1}{B}(1 - p_{ii}).$$

直觉： p_{ii} 越接近 1（正样本已很好区分），梯度越接近 0； p_{ii} 小时梯度为负且绝对值大，推动 s_{ii} 增大，拉近正样本对。

20. ViT 计算量推导 (10 分)

(1) 序列长度 (2 分)

$N_v = \frac{H}{P} \cdot \frac{W}{P}$ ，总序列长度 $N = N_v + 1$ （含 CLS）。

(2) 单层 Self-Attention FLOPs (4 分)

Q, K, V 投影：各 $2Nd^2$ ，共 $6Nd^2$ 。 $S = QK^\top$ ： $2N^2d$ 。 $O = \text{softmax}(S)V$ ： $2N^2d$ 。输出投影： $2Nd^2$ 。
 单层注意力合计 $\approx 8Nd^2 + 4N^2d$ FLOPs。

(3) 分辨率翻倍的影响 (4 分)

224 $\rightarrow$ 448: N_v 从 $14^2 = 196$ 增至 $28^2 = 784$, 约 4 倍。 N 从 197 增至 785。注意力 FLOPs 中 N^2d 项增约 $4^2 = 16$ 倍, Nd^2 项增 4 倍; 显存 $N \times N$ 注意力矩阵增 16 倍。故高分辨率是视觉 token 爆炸的主要来源。

21. 扩散模型推导 (10 分)

(1) $q(x_t|x_0)$ 闭式解 (5 分)

由 $x_t = \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\epsilon_{t-1}$ 递推, 归纳得

$$x_t = \sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\bar{\epsilon}, \quad \bar{\epsilon} \sim \mathcal{N}(0, I),$$

即 $q(x_t|x_0) = \mathcal{N}(\sqrt{\alpha_t}x_0, (1 - \alpha_t)I)$ 。

(2) 简化为噪声预测 (5 分)

原始 ELBO 含多步 KL 项。在 $x_t = \sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\epsilon$ 下, x_0 与 ϵ 一一对应。预测 x_0 等价于预测 ϵ , Ho 等证明加权变分下界可简化为 $\mathbb{E}[\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$, 即直接学习噪声, 训练更稳定且效果相当。

22. LLaVA 架构与训练 (10 分)

(1) 数据流 (4 分)

图像 $\rightarrow$ ViT $\rightarrow [N_v \times d_v] \rightarrow$ 投影器 (Linear/MLP) $\rightarrow [N_v \times d_{\text{LLM}}] \rightarrow$ 与文本 token 嵌入拼接 $\rightarrow$ LLM 自回归生成。投影器将视觉特征映射到 LLM 词嵌入空间。

(2) 两阶段对比 (3 分)

阶段一: 冻结 ViT 与 LLM, 只训练投影器, 用图文对 (如 CC3M) 做 next-token 预测, 学习视觉—语言对齐。阶段二: 解冻 LLM (或 LoRA), 用指令数据 (VQA、对话) 端到端微调, 学习遵循指令与推理。

(3) Token 预算 (3 分)

视觉占比 = $576/(576 + 200) \approx 74\%$ 。高分辨率时 N_v 可超 2k, 易占满 4k 上下文, 需 AnyRes 切图后选择性编码, 或 2×2 pooling 合并 token, 或 Q-Former 压缩。

23. Q-Former 与 Perceiver Resampler (10 分)

(1) Q-Former 结构 (4 分)

N_q 个可学习 query $\mathbf{Q} \in \mathbb{R}^{N_q \times d}$ 作为 Query, ViT 输出 H_v 作为 Key/Value, 经 Cross-Attention: $\text{Attn}(\mathbf{Q}, H_v, H_v)$, 输出 N_q 个视觉 token。ViT 冻结, 只训练 Q-Former 与后续 LLM 接口。

(2) 异同 (3 分)

Q-Former: 独立 BERT 式模块, 输出接 LLM 投影; Flamingo Perceiver Resampler: 在 Flamingo 框架内, 用固定数量 latent 查询视觉特征, 输出注入 LLM 交叉注意力层。二者均为“少量 query + Cross-Attn”压缩, 但集成方式不同。

(3) KV Cache 节省 (3 分)

LLM KV Cache 与序列长度成正比。直接输入: $N_v = 1024$; 压缩后: $N_q = 64$ 。节省倍数 = $1024/64 = 16$ 。32 层 fp16: 约 $2 \times L \times N \times d \times 2$ 字节, 序列减 16 倍则 KV Cache 减 16 倍。

24. 压轴题: 多模态推理系统优化 (10 分)

(1) 高分辨率延迟毛刺 (3 分)

根因：2048 × 2048 单图 AnyRes 切 4 子图，每子图 $N_v \approx 576$ ，总视觉 token $\approx 4 \times 576 = 2304$ ，Prefill 计算量 $\propto N^2$ ，阻塞 Decode。Token 合并：2×2 pooling 将每子图 576 压至 144，总 token $4 \times 144 = 576$ ，减 75%。

(2) 长视频 OOM 方案 (4 分)

10 秒 30 fps 采样 300 帧。每帧 576 token，压缩比 4:1 后每帧 144 token，总视觉 token = $300 \times 144 = 43200$ 。方案：帧采样（如 1 fps 得 10 帧）、Perceiver 压缩、跨帧 KV 复用（相邻帧共享前缀）。优化后 10 帧 × 144 = 1440 token，可纳入 32k 上下文。

(3) 并发与利用率 (3 分)

(1) Continuous Batching：请求级调度，完成即释放，提高并发；(2) 视觉编码器批处理：多图拼 batch 提升 ViT 利用率；(3) Prefix Caching：复用 System Prompt 与共享图像 KV，减少重复 Prefill。预期：SM 利用率从 40% 提升至 60%+，P99 延迟降低 30%+。