

大模型训练与并行计算期末试卷

满分 150 分 考试时间 150 分钟

注

注意事项：

1. 本试卷共三大题，包括选择题、填空题、解答题，共 24 小题。
2. 请将答案写在答题区指定位置；解答题须写出必要的文字说明、推导过程或演算步骤。
3. 涉及数学公式推导时，请清晰写出关键中间步骤；只写最终结果不得分。
4. 本试卷中如无特殊说明，模型参数量记为 Φ ，隐藏维度记为 h ，序列长度记为 s ，批大小组记为 b ，GPU 数量记为 P ，混合精度训练默认使用 fp16/bf16 存储模型权重与梯度，优化器状态使用 fp32 存储。

一、选择题（本大题共 12 小题，每小题 5 分，共 60 分。在每小题给出的四个选项中，只有一项是符合题目要求的。）

1. 在大模型混合精度（Mixed-Precision）训练中，使用 AdamW 优化器并维护 FP32 版本的 Master Weights。对于参数量为 Φ 的模型，仅存储模型参数、梯度和优化器状态（不含激活值与通信缓存），每个参数平均需要占用的显存大小为

(A) 12Φ 字节 (B) 16Φ 字节 (C) 18Φ 字节 (D) 20Φ 字节

2. 根据 Chinchilla Scaling Law (Hoffmann 等人提出的缩放定律)，在给定计算量预算 C （单位：FLOPs）下，模型参数量 N 与训练 Token 数 D 的最优分配比例应满足 $C \approx 6ND$ 。当算力预算增加到原来的 k 倍时，为了达到最优训练效果，模型参数量 N 和训练数据量 D 的理论增长比例大约为

- (A) N 增长 $k^{0.73}$ 倍， D 增长 $k^{0.27}$ 倍
(B) N 增长 $k^{0.5}$ 倍， D 增长 $k^{0.5}$ 倍
(C) N 增长 $k^{0.3}$ 倍， D 增长 $k^{0.7}$ 倍
(D) N 增长 k 倍， D 保持不变

3. 在流水线并行（Pipeline Parallelism）中，采用 1F1B（One Forward, One Backward）调度策略。设流水线阶段数为 P ，一个 Batch 内被切分成的微批数量为 M （满足 $M \geq P$ ）。若单次前向传播时间为 F ，单次反向传播时间为 B ，则在一个完整的训

练步 (Step) 中, 由于气泡导致的处理器空闲时间占总时间的比例 (气泡率) 为

(A) $\frac{P-1}{M+P-1}$ (B) $\frac{P-1}{M}$ (C) $\frac{M-1}{M+P-1}$ (D) $\frac{P}{M}$

4. 在 Megatron-LM 样式的张量并行 (Tensor Parallelism, TP) 中, 一个标准的 Transformer 层包含自注意力 (Self-Attention) 和多层感知机 (MLP) 两个子块。若 TP 的切分大小为 t , 在单层前向传播过程中, 各个 GPU 之间需要进行集体通信。如果不使用序列并行, 该层前向传播总共需要执行的通信操作为

- (A) 2 次 All-Reduce (B) 2 次 All-Gather 和 2 次 Reduce-Scatter
(C) 4 次 All-Reduce (D) 1 次 All-Reduce 和 1 次 All-Gather

5. 在大模型训练中, 激活重计算 (Activation Checkpointing / Gradient Checkpointing) 常用于以计算换显存。若对某一 Transformer 层采用选择性重计算 (Selective Checkpointing) 策略, 丢弃其中 75% 容易重新计算的中间激活值。设该层原本的前向传播计算时间为 T_f , 则采用该策略后, 该层在反向传播时因重计算引入的额外时间开销约为

(A) $0.25T_f$ (B) $0.5T_f$ (C) $0.75T_f$ (D) $1.5T_f$

6. 关于 DeepSpeed 提出的 ZeRO (Zero Redundancy Optimizer) 三种阶段 (Stage 1/2/3) 对模型状态显存的切分, 下列说法错误的是

- (A) ZeRO-1 仅将优化器状态 (Optimizer States) 进行分片存储, 不切分权重和梯度
(B) ZeRO-2 在 ZeRO-1 的基础上, 进一步将梯度 (Gradients) 进行分片存储
(C) ZeRO-3 将优化器状态、梯度和模型权重 (Weights) 均进行分片存储
(D) ZeRO 各阶段通过分片存储激活值 (Activations) 来彻底解决超长文本训练时的 OOM 问题

7. 直接偏好优化 (Direct Preference Optimization, DPO) 是近年来替代传统基于 PPO 算法的 RLHF 的重要方法。已知提示词为 x , 人类偏好的好回答为 y_w , 较差回答为 y_l , 参考模型为 π_{ref} , 当前训练的策略模型为 π_{θ} 。DPO 损失函数 (不含正则项) 的形式为

(A) $-\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) \right]$
(B) $-\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\beta \log \frac{\pi_{\text{ref}}(y_w|x)}{\pi_{\theta}(y_w|x)} - \beta \log \frac{\pi_{\text{ref}}(y_l|x)}{\pi_{\theta}(y_l|x)} \right) \right]$
(C) $-\mathbb{E}_{(x, y_w, y_l)} \left[\beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_l|x)} - \log \sigma \left(\frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_w|x)} \right) \right]$
(D) $-\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\log \frac{\pi_{\theta}(y_w|x)}{\pi_{\theta}(y_l|x)} - \beta \log \frac{\pi_{\text{ref}}(y_w|x)}{\pi_{\text{ref}}(y_l|x)} \right) \right]$

8. 在使用分布式数据并行（DDP）训练时，各节点需要对梯度进行同步。若集群有 P 个 GPU 节点，梯度数据总大小为 V 字节，采用环形全归约（Ring-AllReduce）算法。在每个训练步的梯度同步阶段，每个 GPU 发送的总数据量为

- (A) V 字节 (B) $\frac{2(P-1)V}{P}$ 字节 (C) $\frac{(P-1)V}{P}$ 字节 (D) $2PV$ 字节

9. 在大模型预训练的初始阶段，学习率通常需要经历一个温热启动（Warm-up）阶段（即从 0 渐进增加到设定的最大学习率 $\eta_{\max}$ ），其核心数学与物理机理是

- (A) 随机初始化的权重导致早期梯度极不稳定，较小的学习率可以避免模型在训练初期发散
(B) 增加前期梯度的绝对方差，使得模型更容易跳出局部最优解
(C) 限制前期权重更新的 L2 范数，等效于引入强力的权重衰减（Weight Decay）
(D) 缓解数据分布不均匀导致的早期过拟合

10. 对于一个标准的自回归 Decoder-only Transformer 模型（不使用激活重计算），在单步训练中，反向传播（Backward Pass）阶段所需的计算量（FLOPs）理论上大约是前向传播（Forward Pass）阶段的

- (A) 1 倍 (B) 1.5 倍 (C) 2 倍 (D) 3 倍

11. 在人类反馈强化学习（RLHF）的 PPO 阶段，为了防止策略模型 π_{θ} 偏离初始的 SFT 模型 π_{SFT} 太远导致“奖励作弊（Reward Hacking）”，通常会在奖励函数中引入 KL 散度惩罚。若原始奖励模型输出为 $R(x, y)$ ，惩罚系数为 $\beta > 0$ ，则经 KL 惩罚修正后的实际奖励值 R_{modified} 表达式为

- (A) $R(x, y) - \beta \log \frac{\pi_{\text{SFT}}(y|x)}{\pi_{\theta}(y|x)}$
(B) $R(x, y) - \beta \log \frac{\pi_{\theta}(y|x)}{\pi_{\text{SFT}}(y|x)}$
(C) $R(x, y) + \beta (\pi_{\theta}(y|x) - \pi_{\text{SFT}}(y|x))$
(D) $R(x, y) \cdot e^{-\beta D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{SFT}})}$

12. 在 FP16 混合精度训练中，引入“动态损失缩放”（Dynamic Loss Scaling）机制是为了解决以下哪个数值计算瓶颈？

- (A) 模型权重值过大导致溢出（Overflow）
(B) 梯度数值太小，超出 FP16 的下限表示范围，导致数值下溢（Underflow）归零
(C) 激活值在前向传播中由于矩阵乘法不断累加而造成的数值爆炸
(D) AdamW 优化器在一阶、二阶动量状态更新时的数值溢出

二、填空题（本大题共 6 小题，每小题 5 分，共 30 分。把答案填在题中横线上。）

13. 设某大模型训练任务的全局批大小（Global Batch Size）设为 1024。当前分配了 32 张 GPU 进行数据并行（DP）训练，若每张 GPU 因显存限制最大只能容纳微批大小（Micro-batch Size）为 4，则需要设置的梯度累积步数（Gradient Accumulation Steps）为 _____。

14. 某大模型拥有 $\Phi = 7 \times 10^9$ (7B) 参数。若使用 BF16 混合精度，并采用 AdamW 优化器（每个参数额外维护 FP32 版本的 Master Weight、一阶动量和二阶动量），在不考虑激活值、梯度和通信缓存的前提下，仅存储模型状态（Model States）本身所需的显存大小至少为 _____ GB。（注：结果保留为整数，1 GB = 10^9 字节）

15. 在 Megatron-LM 序列并行（Sequence Parallelism, SP）中，LayerNorm 和 Dropout 的激活值在序列长度维度 S 上被切分。设张量并行大小为 t ，Batch 大小为 B ，隐藏维度为 D 。在单层 Transformer 的前向传播中，由于引入序列并行，每个 GPU 在 SP 相关的通信中（All-Gather 和 Reduce-Scatter 各一次）需要通信的元素（Element）总数为 _____（用 S, B, D, t 表示）。

16. 在 RLHF 偏好对齐中，若词表大小仅为 2（即只有 A, B 两个 Token），对于某特定 Prompt x ，SFT 模型输出分布为 $\pi_{\text{SFT}}(A|x) = 0.5, \pi_{\text{SFT}}(B|x) = 0.5$ ；经过 PPO 训练后的策略模型分布为 $\pi_{\theta}(A|x) = 0.8, \pi_{\theta}(B|x) = 0.2$ 。则当前单步所产生的 KL 散度值 $D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{SFT}})$ 为 _____。（取 $\ln 2 \approx 0.69, \ln 5 \approx 1.61$ ，结果保留两位小数）

17. 在因果语言模型（Causal Language Model）自回归预训练中，为了实现单次前向传播同时计算整个序列所有位置的 Loss，需要引入因果掩码（Causal Mask）。对于位置为 i 的 Query 和位置为 j 的 Key，当 $i < j$ 时，注意力得分矩阵（Attention Score）在 Softmax 之前需要被加上 _____。

18. 假设在一张单卡上训练某一模型时，其吞吐量为 T tokens/s。现在使用 N 张卡构建 DDP 集群进行分布式训练，由于节点间梯度同步通信导致了效率损耗，测得集群的弱扩展效率（Weak Scaling Efficiency）为 90%。则该集群的整体实际训练吞吐量公式为 _____。

三、解答题（本大题共 6 小题，共 60 分。解答应写出文字说明、证明过程或演算步骤。）

19.（本小题满分 10 分）

在大模型预训练中，“训练算力估算”是系统规划的核心。设一个 Decoder-only 架构的 Transformer 模型，其非嵌入层参数量为 N ，隐藏维度为 h ，前向传播中每个 Token 平均经历的操作可以近似简化为矩阵乘法（GEMM）。

(1) 试从矩阵乘法的维度和乘加操作（MAC）的角度，推导证明：对单个 Token 进行前向传播所需的计算量大约为 $2N$ FLOPs；（4 分）

(2) 说明在训练阶段，为什么单步（一次 Forward 和一次 Backward）所需的总计算量大约为 $6N$ FLOPs/token；（4 分）

(3) 现有一款拥有 70B (70×10^9) 参数的模型，准备在含有 2T (2×10^{12}) Tokens 的数据集上进行预训练。若使用一个 A100 GPU 集群进行训练，假设在混合精度和算子优化下，每张卡实际达到的训练吞吐算力（MFU）平均为 150 TFLOPs/s (150×10^{12} FLOPs/s)，估算该预训练任务在 256 张 A100 上需要运行多少天？（2 分）

20.（本小题满分 10 分）

DPO（Direct Preference Optimization）算法通过巧妙的数学变换，直接在偏好数据上优化语言模型，避免了 RLHF 中复杂的强化学习循环。

在标准 RLHF 的对齐目标中，我们希望求解以下受约束的优化问题：

$$\max_{\pi} \mathbb{E}_{x, y \sim \pi} [R(x, y)] - \beta D_{\text{KL}}(\pi(y|x) \parallel \pi_{\text{ref}}(y|x))$$

其中 π_{ref} 是 SFT 模型， π 为待优化的策略模型， $R(x, y)$ 是学到的奖励函数， β 是控制偏离度的常数。

(1) 试证明：上述受约束优化问题的闭式最优解（Optimal Policy）具有如下形式：

$$\pi^*(y|x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp\left(\frac{R(x, y)}{\beta}\right)$$

其中 $Z(x) = \sum_y \pi_{\text{ref}}(y|x) \exp\left(\frac{R(x, y)}{\beta}\right)$ 是归一化配分函数；（5 分）

(2) 结合 Bradley-Terry 偏好模型，即人类偏好 y_w 优于 y_l 的概率满足：

$$P(y_w \succ y_l | x) = \sigma(R(x, y_w) - R(x, y_l))$$

利用 (1) 中的最优解关系，推导消去隐式奖励函数 $R(x, y)$ ，从而给出 DPO 损失函数的数学形式。(5 分)

21. (本小题满分 10 分)

ZeRO (Zero Redundancy Optimizer) 通过消除传统数据并行 (DP) 中的冗余状态，极大降低了单卡显存开销。设模型参数量为 Φ ，分布式数据并行大小 (即 GPU 数量) 为 N_d 。使用 BF16 混合精度和 AdamW 优化器，不考虑激活值。

(1) 写出在标准 DP (未应用 ZeRO)、ZeRO-1、ZeRO-2、ZeRO-3 下，每个 GPU 存储模型状态 (参数、梯度、优化器状态) 所需的显存大小 (用 Φ 和 N_d 表示的函数，单位：字节)；(4 分)

(2) 分析通信开销：标准 DP 每一训练步通过 All-Reduce 进行梯度同步，通信量 (每个 GPU 移入/移出数据量) 为 2Φ 参数个元素。请详细说明 ZeRO-3 在前向传播 (Forward) 和反向传播 (Backward) 中是如何通过集体通信更新和释放权重的，并证明其单步总通信量为标准 DP 的 1.5 倍。(6 分)

22. (本小题满分 10 分)

在优化器设计中，AdamW (Decoupled Weight Decay) 相比传统的 Adam + L2 正则化在训练大模型时具有更好的泛化性能。

(1) 设当前步梯度为 g_t ，一阶动量为 m_t ，二阶动量为 v_t ，学习率为 η_t ，权重衰减系数为 λ 。分别写出 Adam 结合 L2 正则化（即把 $\frac{\lambda}{2}\|\theta\|_2^2$ 显式加进 Loss 中）以及 AdamW 在第 t 步的参数更新方程；（4 分）

(2) 结合上述更新方程，从数学上推导并阐述：为什么在 Adam 优化器中，传统的 L2 正则化机制不能等效于 SGD 中的权重衰减 (Weight Decay)? 而 AdamW 是如何纠正这一偏差的?（6 分）

23. (本小题满分 10 分)

在大规模大模型训练中，通常需要将张量并行 (TP)、流水线并行 (PP) 和数据并行 (DP) 结合，形成“3D 混合并行”。现有一个包含 $G = 32$ 张 GPU 的高带宽互联集群，计划进行 3D 并行配置。

(1) 给出 3D 并行的配置约束等式。若设置张量并行大小为 $t = 4$ ，流水线并行大小为 $p = 4$ ，则数据并行大小 d 应为多少?（2 分）

(2) 为了兼顾通信效率，GPU 分配应当考虑物理拓扑（如单机内 8 卡通过 NVLink 高速互联，机间通过低带宽 InfiniBand 互联）。若有 4 台单机 8 卡物理节点（共 32 卡），GPU 物理编号为 0 到 31。请给出一套合理的 GPU 并行组划分方案，使 TP 组内通信全部限制在物理单机内部，并列出生编号为 0 的 GPU 所在的 TP 组、PP 组和 DP 组包含的所有 GPU 编号；（4 分）

(3) 简述 3D 并行中，为何通常将张量并行限制在单机内部，而流水线并行和数据并行可以跨机布置?（4 分）

24. (本小题满分 10 分, 压轴题)

长文本 (Long Context) 训练是当前大模型的核心竞争点之一。环形注意力 (Ring Attention) 通过在环形拓扑的 GPU 链上切分并循环传递 Key-Value 块, 成功突破了单卡处理超长序列的内存墙。

设待训练的序列长度为 S , 隐藏维度为 D , 注意力头数为 H 。我们使用由 N_{ring} 张 GPU 组成的环形通信拓扑。

(1) 详细描述 Ring Attention 的并行工作原理和数据流向: 如何通过非阻塞对等通信 (Non-blocking P2P Send/Recv), 将局部计算与 KV 块的传输进行重叠 (Overlap), 从而实现无全局 A-matrix (即无 $S \times S$ 完整注意力矩阵) 显存驻留的因果注意力计算; (4 分)

(2) 设 $S = 1,048,576$ (1M), $D = 8192$, $H = 64$ 。若不采用 FlashAttention 也不做任何分块, 直接在单张卡上计算并存储单层的 Softmax 注意力分数矩阵, 假设每个元素使用 FP32 (4 字节) 存储, 计算单层单头注意力矩阵所需的理论显存大小。这说明了什么问题? (3 分)

(3) 结合 FlashAttention (在 SRAM 中完成局部块的 Softmax 和加权累加), 推导说明在使用 Ring Attention 后, 每张 GPU 在计算注意力时, 其显存中与注意力计算相关的核心激活值显存占用 (Q、K、V 激活值) 的复杂度成功降低到了 $O\left(\frac{S}{N_{\text{ring}}} \cdot D\right)$ 。若 $N_{\text{ring}} = 32$, 分析该配置下每张卡的最大文本处理上限能达到怎样的规模? (3 分)

参考答案与解析

一、选择题答案

题号	1	2	3	4	5	6	7	8	9	10	11	12
答案	B	B	A	A	C	D	A	B	A	C	B	B

选择题详细解析

1. **【B】** 混合精度训练各项显存：权重 FP16/BF16 占 2Φ 字节；梯度 FP16/BF16 占 2Φ 字节；AdamW 优化器状态含 FP32 Master Weight (4Φ)、一阶动量 m (4Φ)、二阶动量 v (4Φ)，共 12Φ 字节。总显存 $2\Phi + 2\Phi + 12\Phi = 16\Phi$ 字节。

2. **【B】** Chinchilla Scaling Law 证明，算力增加时参数量 N 和数据量 D 应以大致相等的比例缩放 ($N \propto C^{0.5}$, $D \propto C^{0.5}$)。旧 Kaplan 定律 (2020) 认为 $N \propto C^{0.73}$ ，Chinchilla 已修正。

3. **【A】** 1F1B 调度中气泡集中在首尾。总运行时间为 $(M + P - 1)(F + B)$ ，气泡时间为 $(P - 1)(F + B)$ ，故气泡率 = $\frac{P - 1}{M + P - 1}$ 。

4. **【A】** Megatron TP 中：自注意力块 O 矩阵行切分需 1 次 All-Reduce；MLP 第二层行切分需 1 次 All-Reduce。单层前向共 2 次 All-Reduce。

5. **【C】** 丢弃 75% 激活值意味着反向传播时需对这 75% 的部分重新进行前向传播，额外时间开销约为 $0.75T_f$ 。

6. **【D】** ZeRO 解决的是模型状态冗余存储，并不对激活值做物理切分。长文本 OOM 主要由激活值引起，需靠序列并行 (SP)、FlashAttention 或 Ring Attention 解决。

7. **【A】** DPO 损失由 RLHF 闭式解求反函数导出：

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) \right]$$

以 π_{ref} 作为隐式 KL 散度约束。

8. **【B】** Ring-AllReduce 含 Scatter-Reduce 和 All-Gather 两阶段，每阶段传 $(P - 1)$ 次大小为 V/P 的数据包，总发送量 = $\frac{2(P - 1)V}{P}$ 字节。

9. **【A】** 训练初期随机初始化权重使梯度极大且方向多变，直接用大学习率易导致发散。Warm-up 通过较小步长让模型逐步适应数据分布，使梯度稳定。

10. **【C】** 前向传播： $Y = XW$ ($2N$ FLOPs/token)。反向需两次同等规模矩阵乘：

激活梯度 $\partial L/\partial X = (\partial L/\partial Y)W^T$ 和权重梯度 $\partial L/\partial W = X^T(\partial L/\partial Y)$ ，合计 $4N$ FLOPs/token，是前向的 2 倍。

11. 【B】 PPO 目标最大化修正奖励减 KL 惩罚： $\text{Obj} = R(x, y) - \beta \log \frac{\pi_\theta(y|x)}{\pi_{\text{SFT}}(y|x)}$ ，故 $R_{\text{modified}} = R(x, y) - \beta \log \frac{\pi_\theta(y|x)}{\pi_{\text{SFT}}(y|x)}$ 。

12. 【B】 FP16 最小正非零正常数约 6.10×10^{-5} ，许多梯度落在 $[10^{-8}, 10^{-5}]$ 被截断为 0（下溢）。动态损失缩放将 Loss 乘大因子 S 放大梯度至 FP16 可表示范围，更新前再除以 S 。

二、填空题答案

题号	13	14	15	题号	16	17	18
答案	8	112	$2\frac{t-1}{t}SBD$	答案	0.19	$-\infty$	$0.9NT$

填空题详细解析

13. 【8】 全局批大小等式：Global BS = GPU 数 $\times$ Micro BS $\times$ Accum Steps。代入 $1024 = 32 \times 4 \times n \Rightarrow n = 8$ 。

14. 【112】 每参数模型状态显存 16 字节。 $7 \times 10^9 \times 16 = 112 \times 10^9$ 字节 = 112 GB。

15. 【 $2\frac{t-1}{t}SBD$ 】 SP 中 All-Gather 通信量为 $\frac{t-1}{t}SBD$ ，Reduce-Scatter 同样为 $\frac{t-1}{t}SBD$ ，合计 $2\frac{t-1}{t}SBD$ 。

16. 【0.19】

$$D_{\text{KL}} = 0.8 \ln \frac{0.8}{0.5} + 0.2 \ln \frac{0.2}{0.5} = 0.8 \ln 1.6 + 0.2 \ln 0.4 \approx 0.8(0.47) + 0.2(-0.92) \approx 0.19$$

17. 【 $-\infty$ （或极小负数，如 -10^9 ）】 $i < j$ 时 Query 不应看到未来位置 j 的 Key，Softmax 前加 $-\infty$ 使对应注意力权重严格归零。

18. 【 $0.9NT$ 】 弱扩展效率 90% 时，实际总吞吐量 = $N \cdot T \cdot 90\% = 0.9NT$ 。

三、解答题详细解析

19. 【解析】

(1) Transformer 各层参数集中于投影矩阵。单层隐藏维度 h : Q/K/V 投影各 $[h, h]$ 共 $3h^2$ 参数 $\Rightarrow 3h^2$ MACs; 输出投影 O 贡献 h^2 MACs; MLP (门控) 升维 $h \rightarrow 4h$ 两个线性层 + 降维 $4h \rightarrow h$ 共约 $12h^2$ MACs。每 MAC 含 1 乘 1 加 = 2 FLOPs。单层总计 $\approx 24h^2$ FLOPs = $2N_{\text{layer}}$ FLOPs/token。推广到全模型 L 层: $\sum_l 2N_l = 2N$ FLOPs/token。 (证毕)

(2) 前向传播: $2N$ FLOPs/token。反向传播含两部分: (i) 激活梯度 $2N$ FLOPs/token, (ii) 权重梯度 $2N$ FLOPs/token, 合计 $4N$ FLOPs/token。单步总计 $2N + 4N = 6N$ FLOPs/token。 (证毕)

(3) 总计算量 $C = 6 \times 70 \times 10^9 \times 2 \times 10^{12} = 8.4 \times 10^{23}$ FLOPs。单张 A100 日吞吐 $150 \times 10^{12} \times 86400 \approx 1.296 \times 10^{19}$ FLOPs/day, 256 张日吞吐 $\approx 3.318 \times 10^{21}$ FLOPs/day。所需天数 $= \frac{8.4 \times 10^{23}}{3.318 \times 10^{21}} \approx \boxed{253}$ 天。

20. 【解析】

(1) 将目标函数改写为:

$$\beta \sum_y \pi(y|x) [\log(\pi_{\text{ref}}(y|x)e^{R(x,y)/\beta}) - \log \pi(y|x)]$$

定义 $\pi^*(y|x) = Z(x)^{-1} \pi_{\text{ref}}(y|x)e^{R(x,y)/\beta}$, 其中 $Z(x)$ 为归一化配分函数, 则上式化为:

$$\beta \log Z(x) - \beta D_{\text{KL}}(\pi(y|x) \parallel \pi^*(y|x))$$

因 $\beta \log Z(x)$ 与 π 无关, 且 $D_{\text{KL}} \geq 0$, 目标在 $D_{\text{KL}} = 0$ 即 $\pi = \pi^*$ 时取最大值。 (证毕)

(2) 由最优解取对数: $R(x, y) = \beta \log \frac{\pi^*(y|x)}{\pi_{\text{ref}}(y|x)} + \beta \log Z(x)$ 。代入 Bradley-Terry 模型作差, $Z(x)$ 完全消去:

$$R(x, y_w) - R(x, y_l) = \beta \log \frac{\pi^*(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi^*(y_l|x)}{\pi_{\text{ref}}(y_l|x)}$$

用 π_θ 替换 π^* , 对偏好数据集做最大似然估计, 负对数似然即为 DPO 损失:

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\beta \log \frac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) \right]$$

(推导毕)

21. 【解析】

(1) 各阶段单卡显存 (BF16 + AdamW, 权重 2Φ 字节、梯度 2Φ 字节、优化器状态 12Φ 字节):

- 标准 DP: $M_{\text{DP}} = 2\Phi + 2\Phi + 12\Phi = 16\Phi$ 字节
- ZeRO-1 (仅切优化器状态): $M_1 = 4\Phi + \frac{12\Phi}{N_d}$ 字节
- ZeRO-2 (切梯度 + 优化器状态): $M_2 = 2\Phi + \frac{14\Phi}{N_d}$ 字节
- ZeRO-3 (全部切分): $M_3 = \frac{16\Phi}{N_d}$ 字节

(2) ZeRO-3 通信流程:

前向传播: 每层计算前, GPU 发起 All-Gather 汇聚完整权重 (全网通信量 Φ), 计算完成后立即释放额外权重。

反向传播: 每层先 All-Gather 完整权重 (Φ), 计算梯度后通过 Reduce-Scatter 归约并按分片存储 (Φ), 随后释放非本分片梯度。

通信量对比: 标准 DP 的 All-Reduce $\equiv$ Reduce-Scatter + All-Gather = 2Φ ; ZeRO-3 = 前向 All-Gather (Φ) + 反向 All-Gather (Φ) + 反向 Reduce-Scatter (Φ) = 3Φ 。比值 $\frac{3\Phi}{2\Phi} = \boxed{1.5}$ 。(证毕)

22. 【解析】

(1) **Adam + L2 正则化**: 引入正则后梯度 $\tilde{g}_t = \nabla \mathcal{L}(\theta_t) + \lambda \theta_t$, 动量用 $\tilde{g}_t$ 计算:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \tilde{g}_t, \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2) \tilde{g}_t^2$$

$$\theta_{t+1} = \theta_t - \frac{\eta_t}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t$$

AdamW: 梯度 $g_t = \nabla \mathcal{L}(\theta_t)$ (不含正则), 动量用 g_t 计算 (公式同上), 最终更新时权重衰减独立剥离:

$$\theta_{t+1} = \theta_t - \eta_t \lambda \theta_t - \frac{\eta_t}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t$$

(2) SGD 中 L2 正则使 $\theta_{t+1} = (1 - \eta_t \lambda) \theta_t - \eta_t g_t$, 与权重衰减完全等价。但在 Adam 中, L2 正则项进入 $\hat{m}_t$, 最终被二阶动量缩放:

$$\theta_{t+1} \approx \theta_t - \frac{\eta_t}{\sqrt{\hat{v}_t} + \epsilon} (\nabla \mathcal{L} + \lambda \theta_t)$$

大 $\hat{v}_t$ 的权重其衰减强度被削弱至 $\lambda / \sqrt{\hat{v}_t} < \lambda$; 小 $\hat{v}_t$ 的权重反而被放大, 正则化不均匀。

AdamW 的纠正: 将 $\lambda \theta_t$ 从动量中剥离, 直接写入更新步。无论历史梯度如何, 每步衰减比例恒为 $\eta_t \lambda$, 不受 $\sqrt{\hat{v}_t}$ 干扰, 完美恢复权重衰减初衷, 在大模型训练中展现出极佳的泛化性和数值稳定性。 (论证毕)

23. 【解析】

(1) 约束等式 $G = t \times p \times d$ 。代入 $32 = 4 \times 4 \times d \Rightarrow d = 2$ 。

(2) 4 台 8 卡节点 (Node 0-3, GPU 0-31), $t = 4$ 使每机容纳 2 个 TP 组。GPU 0 的并行组归属如下:

- **TP 组** (机内 NVLink, 4 卡): [0, 1, 2, 3]
- **PP 组** (跨机对应 Stage, 4 卡): [0, 4, 8, 12]
- **DP 组** (相同 PP stage 的数据副本, 2 卡): [0, 16]

(3) TP 在每层前/反向均需高频 All-Reduce (每个 Transformer 层数次), 对延迟和带宽极敏感, 跨机将立刻因 InfiniBand 带宽瓶颈导致 GPU 严重空闲, 故**必须限制在单机 NVLink 内**。PP 仅在 Stage 边界传输边界激活值, 通信频率低、数据量相对小, 跨机 IB 可接受。DP 仅在反向结束后进行梯度同步 (Bucket 化异步 All-Reduce), Global Batch Size 越大频率越低, 跨机 IB 轻松承载。

24. 【解析】

(1) 空间切分: 序列均分为 N_{ring} 份, 每 GPU 持有长度为 S/N_{ring} 的 Q_i, K_i, V_i 块。

环通信与计算重叠流程：(a) GPU i 用本地 Q_i 与 K_i 计算注意力并累加 V_i 的贡献；(b) 同时非阻塞发送 (K_i, V_i) 至邻居 $i + 1$ ，并从 $i - 1$ 接收新的 KV 块；(c) 通信完成后立即用新收到的 KV 块继续计算；(d) 循环 $N_{\text{ring}} - 1$ 轮，直至每个 GPU 的 Q_i 与全网所有 KV 块均完成计算。全程仅在块级做局部 Softmax + 加权累加（借助 FlashAttention 的 online softmax），HBM 中从未实例化 $S \times S$ 矩阵。

(2) 单层单头注意力矩阵大小 $S \times S = 1,048,576^2 \approx 1.10 \times 10^{12}$ 元素，FP32 存储需 $1.10 \times 10^{12} \times 4 \approx 4.4 \times 10^{12}$ 字节 ≈ 4.4 TB。这远超 A100-80GB 的单卡显存容量（约 55 倍），说明不加分块的长文本注意力计算在物理上完全不可行。

(3) FlashAttention + Ring Attention 使 HBM 仅常驻本地 Q_i 块 ($\frac{S}{N_{\text{ring}}} \times D$)、KV 双缓冲 ($2 \times \frac{S}{N_{\text{ring}}} \times D$) 和输出 O ($\frac{S}{N_{\text{ring}}} \times D$)，总复杂度 $O\left(\frac{S}{N_{\text{ring}}} \cdot D\right)$ 。当 $N_{\text{ring}} = 32$ ，1M 序列时每卡等效处理长度仅 $\approx 31,250$ token，激活值仅数 GB。凭借线性扩展性，32 卡集群理论可支持 **2M–4M** 规模的超长文本训练。（分析毕）